

DIAGNOSTIC D'UNE MALADIE CARDIAQUE

MACHINE LEARNING POUR TOUS- ML01, Groupe 21

FIORITI Federico Pascual, MAZZANTE Lorenzo, PORTELA Juana, SCORZA Martin

Pourquoi ce sujet est-t-il important ?


1ère cause de mortalité
chez la femme

1ère cause de
mortalité dans le
monde

1,2 million
d'hospitalisations
par an

Coût des maladies
cardiovasculaires: 19
milliards / an

400 décès
par jour chez
les adultes



Problématique

Malgré les progrès médicaux, le diagnostic d'une maladie cardiaque reste complexe. Il faut analyser de nombreux paramètres, et certaines combinaisons restent difficiles à interpréter.



Comment identifier rapidement et avec précision les patients susceptibles de développer une maladie cardiaque ?

C'est la question à laquelle essaie de répondre notre projet.

Objectif

Le but de notre travail est de développer un modèle de machine learning capable de prédire la présence ou l'absence d'une maladie cardiaque chez un patient à partir de ses données cliniques.

ÉTUDE DE LA BASE DE DONNÉS

La base de données a été récupérée sur le site web d'OpenML.

Nombre d'observations:

70.000

Classes:

0 (patient en bonne santé),
1 (patient malade)

5 variables numériques:

âge, taille, poids,
pression systolique et diastolique

6 variables catégorielles:


sexe, cholestérol, glucose,
tabagisme, alcool, activité physique

Nettoyage et préparation des données

Avant l'entraînement des modèles, plusieurs étapes de pré-traitement ont été réalisées:

- suppression des valeurs illogiques;
- élimination des variables non pertinentes (ex. Identifiant (ID))


MATRICE DE CORRÉLATION




ON TE RÉSUME : Prends soin de toi !

- Plus de poids = plus de pression dans les artères
- Mauvaise alimentation = cholestérol élevé et glucose élevé
- Attention au combo cigarette + alcool
- Avec l'âge, la tension et le cholestérol ont tendance à monter
- Activité physique = bonne tension, un meilleur cholestérol et une glycémie plus stable.


PROPORTION PAR CLASSE



CARDIOPATIE SELON ACTIVITÉ PHYSIQUE




Les mêmes graphiques ont été faits pour d'autres variables afin de visualiser leur distribution.




COMMENT LE PRÉDIRE ? →

Méthodes de MACHINE LEARNING

MODÈLES UTILISÉS



→ PPV




**Q OPTIMAL =
40 voisins**


↓ Q → Erreur train ↓
Erreur test ↑
↑ Q → Erreurs stables
Erreur test ↓

REGRESSION LOGISTIQUE

Frontière de décision en prenant en compte les variables les plus pertinentes : Âge et pression systolique





→ EUCLIDIAN



REGRESSION LOGISTIQUE OPTIMISÉE:

Y A-T-IL DES VARIABLES QUI N'ONT PAS UN RÔLE DÉCISIF ? : MÉTHODE LASSO




COMPROMIS CHERCHÉ :

ACCURACY



VS
QUANTITÉ DE
VARIABLES
UTILISÉE



PRESSION
DYASTOLIQUE,
FUMEUR,
BUVEUR

→ DESICION TREE

IMPORTANCE DES VARIABLES selon notre arbre:

1) pression artérielle systolique

2) l'âge.

Il utilise ces deux variables pour séparer les personnes avec ou sans maladie.

ap_hi ≤ 129.5
gini = 0.5
samples = 3750
value = [1913, 1837]
class = Non-Disease

True

False

age ≤ 55.5
gini = 0.429
samples = 2253
value = [1550, 703]
class = Non-Disease

ap_hi ≤ 133.0
gini = 0.367
samples = 1497
value = [363, 1134]
class = Disease


gini = 0.35
samples = 1527
value = [1182, 345]
class = Non-Disease

gini = 0.5
samples = 726
value = [368, 358]
class = Non-Disease

gini = 0.479
samples = 498
value = [198, 300]
class = Disease



Distribución de la accuracy por modèle





Information statistique sur la distribution de l'accuracy dans la base test pour chaque modèle (médiane et variabilité entre folds). Toutes les准确ies restent proches, autour de 70-72 %.



L'EFFET SUR NOTRE PLANÈTE

Les barres montrent les émissions moyennes de CO₂ de chaque modèle.



CONCLUSION: NOS CHOIX

Eucledian

Il présente une très haute précision, tout en étant le modèle le moins consommateur.

Plus Proches Voisins

C'est le modèle qui offre la meilleure précision, mais aussi celui qui consomme le plus de ressources.

Arbre de décision

Il présente une très haute précision, tout en affichant une émissions de carbone moyenne